SK네트웍스 Family AI 과정 10기

인공지능 데이터 전처리 결과서

산출물 단계	데이터 전처리
평가 산출물	인공지능 데이터 전처리 결과서
제출 일자	2025.06.13
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN10-FINAL-3Team.git
작성 팀원	배민경

1. 문서 개요

● 전처리 목적

판례 본문 데이터를 텍스트 분류 모델 학습에 적합하도록 정제

● 문제 정의

법률 판례 원문과 결과(인용, 기각 등)를 기반으로 분류 모델을 학습하여, 향후 사용자 질의에 적합한 판례 자동 분류 및 유사 사례 추천 기능에 활용하기 위한 데이터셋 구축

2. 데이터셋 개요

● 데이터 출처 및 수집 방법

- 대법원 공개 판례 데이터 기반
- 오픈 API를 통해 수집한 판결문 전문과 결과(인용, 기각 등)
- 모델 학습 목적의 가공 및 구조화 수행

● 데이터 구성

항목명	**설명**	**예시**
판례정보일련번호	판례 고유 식별 번호	64763
사건번호	사건 고유 번호	2006다18228
선고일자	판결이 선고된 날짜 (YYYYMMDD 형식)	20080925
선고	선고 여부 (대부분 "선고" 값)	선고
법원명	판결을 내린 법원명	대법원
법원종류코드	법원 종류 코드 (예: 대법원 = 400201)	400201
사건명	사건 제목	손해배상(기)

사건종류명	사건 분류 (민사, 형사 등)	민사
사건종류코드	사건 종류 코드	400101
판시사항	해당 판례의 쟁점 요약	"행정지도가 한계를 일탈한 경우..."
판결요지	요약된 판결 요지	(없음 or 텍스트)
참조조문	참조한 법률 조항 목록	민법 제750조, 제2조...
참조판례	참조한 이전 판례	2006다19603 등
판례내용	판례 전문 (입력 텍스트로 사용할 수 있음)	"【원고, 피상고인】...
판결유형	판결 or 결정 등 유형	판결

● 데이터 샘플

data > {} 64763.json > ...


```
{
    "판시사항": "[1] 한계를 일탈하지 않은 행정지도로 인하여 상대방에게 손해가 발생한 경우, 행정기관이 손해배상책임을 지는지 여부(소극)<br/>[2] 행
    "참조판례": "[2]대법원 2005. 10. 28. 선고 2003다69638 판결(공2005하, 1847),대법원 2007. 11. 16. 선고 2005다3229 판결,대법원 2007. 11. 30. 선고
    "사건종류명": "민사",
    "판결요지": "[1] 행정지도가 강제성을 띠지 않은 비권력적 작용으로서 행정지도의 한계를 일탈하지 아니하였다면, 그로 인하여 상대방에게 어떤 손해가
    "참조조문": "[1]행정절차법 제48조,민법 제750조 / [2]민법 제393조,제763조 / [3]민법 제168조 제3호 / [4]민법 제2조,제162조 제1항<br/>",
    "선고일자": "20080925",
    "법원명": "대법원",
    "사건명": "손해배상(기)",
    "판례내용": "【원고(탈퇴)】 <br/>【원고승계참가인, 상고인 겸 피상고인】 <br/>【피고, 피상고인 겸 상고인】 인천광역시 강화군 (소송대리인 변호사
    "사건번호": "2006다18228",
    "사건종류코드": "400101",
    "판례정보일련번호": "64763",
    "선고": "선고",
    "판결유형": "판결",
    "법원종류코드": "400201"
}
```


data > {} 64821.json > ...


```
{
    "판시사항": "[1] 의사의 진단상 과실 유무의 판단 기준 및 의사가 의료기관의 설비 등 여러 가지 사정으로 진단에 필요한 검사를 실시할 수 없는 경우
    "참조판례": "[1]대법원 2003. 1. 24. 선고 2002다3822 판결(공2003상, 705),대법원 2004. 10. 28. 선고 2002다45185 판결(공2004하, 1929),대법원 200
    "사건종류명": "민사",
    "판결요지": "[1] 의사의 진단상 과실 유무를 판단함에 있어, 진단은 문진·시진·촉진·청진 및 각종 임상검사 등의 결과에 터잡아 질병 여부를 감별하고
    "참조조문": "[1]민법 제750조 / [2]민법 제750조<br/>",
    "선고일자": "20080919",
    "법원명": "울산지법",
    "사건명": "손해배상(의)",
    "판례내용": "【원 고】 <br/>【피 고】 <br/>【변론종결】2008. 9. 5.<br/>【주 문】<br/>1. 피고는원고 1에게 58,115,160원,원고 2,원고 30
    "사건번호": "2006가단52265",
    "사건종류코드": "400101",
    "판례정보일련번호": "64821",
    "선고": "선고",
    "판결유형": "판결 : 확정",
    "법원종류코드": "400202"
}
```

data > {} 64895.json > ...


```
{
    "판시사항": "[1] 기업체의 대규모 분식회계사실을 밝히지 못한 외부감사인의 회계감사상의 과실과 투자자의 기업체 발행 기업어음 매입행위 사이의 인
    "참조판례": "[1]대법원 2007. 1. 11. 선고 2005다28082 판결(공2007상, 270) / [2]대법원 2007. 10. 25. 선고 2006다16758, 16765 판결(공2007하, 180
    "사건종류명": "민사",
    "판결요지": "",
    "참조조문": "[1]민법 제750조,주식회사의 외부감사에 관한 법률 제2조,제7조의2,제17조 제2항 / [2]민법 제393조,제750조,제763조,주식회사의 외부감사
    "선고일자": "20080626",
    "법원명": "대법원",
    "사건명": "손해배상(기)",
    "판례내용": "【 원고, 피상고인 】 주식회사 대송상호저축은행 (소송대리인 법무법인 한누리 담당변호사 김상원외 3인)<br/>【 피고, 상고인 】 안건회계법
    "사건번호": "2007다13985",
    "사건종류코드": "400101",
    "판례정보일련번호": "64895",
    "선고": "선고",
    "판결유형": "판결",
    "법원종류코드": "400201"
}
```


data > {} 64913.json > ...


```
{
    "판시사항": "[1] 불법행위 당시에는 예견할 수 없었던 새로운 손해가 발생하거나 예상외로 손해가 확대된 경우, 손해배상청구권의 시효소멸기간의 진행
    "참조판례": "[1]대법원 1982. 3. 9. 선고 81다977, 81다카500 판결(공1982, 431),대법원 1991. 3. 22. 선고 90다8152 판결(공1991, 1242),대법원 2001
    "사건종류명": "민사",
    "판결요지": "",
    "참조조문": "[1]민법 제766조 / [2]민법 제766조<br/>",
    "선고일자": "20080710",
    "법원명": "대법원",
    "사건명": "손해배상(산)",
    "판례내용": "【 원고(선정당사자), 상고인 】 <br/>【 피고, 피상고인 】 주식회사 유성티엔에스 (소송대리인 법무법인 비전인터내셔널 담당변호사 박영만
    "사건번호": "2008다21518",
    "사건종류코드": "400101",
    "판례정보일련번호": "64913",
    "선고": "선고",
    "판결유형": "판결",
    "법원종류코드": "400201"
}
```


data > {} 64943.json > ...


```
{
    "판시사항": "[1] 낮은 곳의 토지 소유자가 지반고를 높이거나 제방을 쌓아 높은 곳으로부터 자연히 흘러오는 우수의 흐름을 막은 경우,민법 제221조 제
    "참조판례": "[1]대법원 1995. 10. 13. 선고 94다31488 판결(공1995하, 3754) / [2]대법원 1998. 2. 27. 선고 97다38442 판결(공1998상, 872),대법원 2
    "사건종류명": "민사",
    "판결요지": "",
    "참조조문": "[1]민법 제221조 제1항 / [2]민사소송법 제136조<br/>",
    "선고일자": "20080724",
    "법원명": "대법원",
    "사건명": "손해배상(기)",
    "판례내용": "【 원고, 피상고인 겸 상고인 】 <br/>【 원고, 피상고인 】 <br/>【 피고, 상고인 겸 피상고인 】 <br/>【 원심판결 】 대구고법 2007. 6. 13. 선
    "사건번호": "2007다50663",
    "사건종류코드": "400101",
    "판례정보일련번호": "64943",
    "선고": "선고",
    "판결유형": "판결",
    "법원종류코드": "400201"
}
```

3. 전처리 프로세스 개요

● 전체 흐름도

① 판례 수집 → ② 텍스트 정제 → ③ 라벨링 → ④ 토크나이징 → ⑤ 학습/검증/테스트 분리

● 전처리 파이프라인 요약

단계	목적	수행 작업	사용 도구/라이브러리
데이터 구조화	원시판례 JSON 정제 및 통합	사건번호, 판례내용, 선고일자 등 주요 필드 추출	json, pandas
텍스트 정제	불필요한 태그 및 특수문자 제거	 , 공백, 특수문자 등 제거	re, string
라벨링	판결 결과 라벨 부여	"기각", "인용" 등의 키워드 기반 정수 매핑	수동 규칙 기반 매핑
토크나이징	모델 입력을 위한 텍스트 토큰화	input_ids, attention_mask 생성, 최대 512 토큰 자름 처리	BertTokenizer (transformers)
이상치 대응	소수 클래스 제거로 평가 안정성 확보	테스트셋 내 샘플 수 5개 미만 라벨(3, 6) 제거	pandas
데이터 분할	학습/검증/테스트 세트 나누기	Train : val : test = 7:2:1 비율로 분할	sklearn.model_selection.train_test_split

4. 전처리 상세

4.1 결측치 처리

● 결측치 존재 여부: 없음

- 판례 데이터는 대법원 공개 API 또는 수집된 JSON 파일 기반이며, 주요 필드(판례내용, 사건번호, 선고일자)에 결측값이 존재하지 않음

4.2 이상치 처리

● 정의한 이상치 기준

- 테스트셋 내 라벨(Class 3, 6):
  → 샘플 수 10개 미만으로, 평가 지표 신뢰도 확보 불가능

→ 소수 클래스 제거

● 처리 방식 및 영향

항목	기준	처리 방식	제거 수
라벨 분포 불균형	테스트셋 내 클래스 3, 6의 샘플 수 < 10	해당 클래스 행 제거	'각하' : 7건 '취하' : 1건

4.3 정규화 및 표준화

● 텍스트 정규화

판례 원문은 HTML 형식과 머리말 등 불필요한 형식 요소가 많기 때문에,
모델 입력에 적합하도록 다음과 같은 정제 작업을 수행함

항목	설명	예시 Before	예시 After
머리말 분리	【원고】, 【이유】, 【주문】 등 판결 구조 구분 텍스트를 별도 필드로 분리	"【이 유】 원심은..."	"원심은..."
HTML 태그 제거	 , <b>, 등 HTML 마크업 제거	"판결 선고"	"판결 선고"
공백 정리	이중 개행, 들여쓰기, 반복 공백 제거	"피고는₩n₩n₩n책임이 있다."	"피고는 책임이 있다."

● 수치형 표준화: 해당 없음

- 본 데이터는 판례 전문 기반의 텍스트 분류 모델 학습을 위한 것이므로 수치형 feature가 존재하지 않음

● 사용 라이브러리

- re: 정규표현식 기반 머리말 및 HTML 태그 제거
- pandas: 데이터 정제 및 정렬

4.4 데이터 변환 및 생성

● 레이블 인코딩: 판결 결과 텍스트 → 숫자 라벨

판결 결과를 정수형 라벨로 인코딩하여 모델 입력용 분류 클래스 생성

```
data > {} label_map.json > ...
{
    "인용": 0,
    "일부인용": 1,
    "기각": 2,
    "각하": 3,
    "파기환송": 4,
    "원심유지": 5,
    "취하": 6,
    "파기환송, 원심유지": 7
}
```

● 일부 라벨(예: 3, 6)은 테스트셋 내 소수 클래스라서 평가셋에서 제외됨 (상세 내용: 4.2 이상치 처리)

4.4.1. 판례 결과 라벨링 및 학습 데이터셋 구축 절차

● 전용 라벨링 툴 개발

판례 내용을 효율적으로 검토하고 라벨을 지정할 수 있도록 내부용 라벨링 툴을 자체 개발하였다.

- 주요 기능: 판례 전문 확인, 원고 기준 라벨 선택, 결과 자동 저장
- 목적: 대량의 판례 데이터를 빠르고 일관성 있게 처리하기 위한 기반 환경 구축

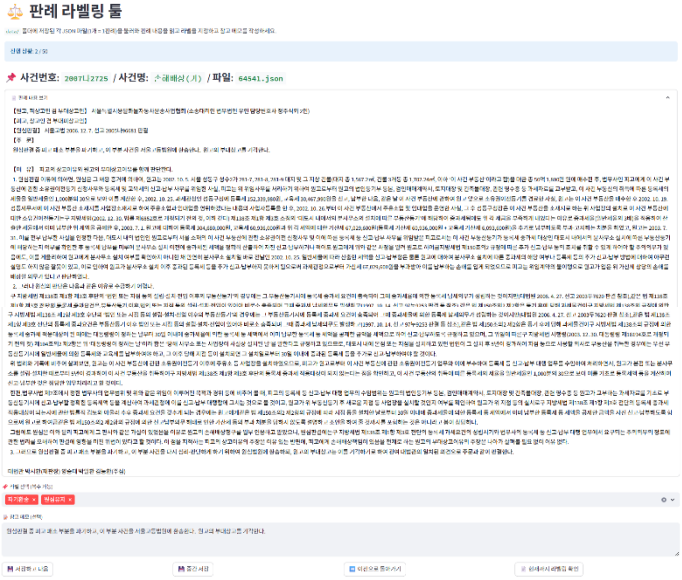

● 수작업 라벨링 수행

실제 판례의 주문문과 판시사항을 기반으로, 원고 기준으로 라벨을 부여하였다.

- 사용된 라벨: 인용, 기각, 일부 인용, 각하, 조정
- 기준: 주문문 중심 해석, 필요 시 판결 이유와 본문 내용 검토

● ChatGPT 기반 자동 라벨링 결과 생성

수작업 결과와 비교 평가를 위해, 동일한 판례 데이터에 대해 ChatGPT로 자동 라벨링을 수행하였다.

- 방법: 시스템 프롬프트 기반 분류, 원고 기준 명시
- 결과: 자동 라벨링 결과와 수작업 결과 간 일치 여부 확인

● 라벨 비교 및 정합성 검토

수작업과 ChatGPT 라벨 간 비교 분석을 통해 정확도와 오류 유형을 파악하였다.

- 주요 불일치 원인: 주문문 해석의 모호성, 원고-피고 기준 혼동, 문맥 오류
- 판단 기준이 애매한 사례는 별도로 분류하고 라벨링 기준 정비

● 최종 학습 데이터셋 구성

검토를 마친 데이터 중 라벨 정합성이 확보된 사례만 선별하여 최종 학습용 데이터셋을 구성하였다.

- 구성 항목: 사건번호, 판결문 본문, 결과 라벨
- 활용 목적: BERT 기반 결과 분류 모델 학습, RAG 시스템 라벨링 전처리 등

5. 학습/검증/테스트 데이터 분리

● 분리 기준 및 방법

항목	내용
기준	무작위 분할 + **라벨 비율 유지 (Stratified)**
비율	학습:검증 = 9.5 : 0.5
샘플 단위	판례내용 단위 (document-level)

● 분리 후 건수

구분	데이터 수 (건)
학습 데이터	2,126건
검증 데이터	112건

6. 전처리 결과 요약 및 평가

● 전처리 후 전체 건수

항목	건수
원본 총 데이터	2238
최종 정제 후	2230

● 품질 향상 요약

항목	내용
결측값 제거 없음	판례 구조상 필수 필드 결측 없음
이상치 제거	테스트셋 내 소수 라벨(Class 3, 6) 제거 → 8건
라벨 정리	총 8개 클래스 통일 정리 및 수동 매핑 적용

● **향후 활용 방안**

- **법률 텍스트 분류 모델 학습**
- **유사 판례 검색 및 판례 기반 질의응답 시스템 학습 데이터로 재사용**