SK네트웍스 Family AI 과정 10기

데이터 전처리 인공지능 학습 결과서

산출물 단계	데이터 전처리
평가 산출물	인공지능 학습 결과서
제출 일자	2025.06.13
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN10-FINAL-3Team.git
작성 팀원	배민경

1. 모델 비교 및 선정 이유

● 비교 대상 모델 ①: 다른 구조 기반 모델 간 비교

모델명	특징	선정된 이유
BERT	Transformer 기반 사전학습 모델	문맥을 깊이 있게 이해할 수 있어 긴 법률 문장 처리에 강점을 보이며, 사전 학습된 파라미터 활용과 결과 재현이 용이함
BiLSTM	RNN 구조의 양방향 모델	문장의 앞뒤 흐름을 모두 반영할 수 있으나, 긴 문장에서 정보 손실이 발생할 수 있고 학습 속도도 느림
TextCNN	CNN 기반 분류 모델	고정된 길이의 문장에서 핵심 키워드를 빠르게 추출하는 데 효과적이나, 문장 전체 구조 파악에는 한계가 있음

→ 위 모델들은 구조적으로 서로 다른 방식으로 문장을 처리하며, 문헌 기반 비교 결과 Transformer 기반 모델의 문맥 표현력이 법률 문서 분류에 가장 적합함이 확인되었다.

● 비교 대상 모델 ②: BERT 계열 내 모델 간 비교

모델명	종류	주요 특징
bert-base-multilingual-cased	Google 공식 사전학습 모델	104개 언어 대상 대규모 말뭉치 학습, Hugging Face 생태계 호환성 우수, 긴 문장 처리 성능 양호
KoBERT	한국어 전용 Transformer	한국어 뉴스 기반 학습, 추론 속도 빠름, 다만 업데이트 중단으로 최신 환경 대응 부족
KcBERT (beomi/KcBERT-base)	한국어 특화 Transformer	커뮤니티 주도 개발, 비속어·신조어 대응력 우수, 긴 문장에서 표현력 강점, 다만 공식 유지관리 부족
KLUE-BERT (klue/bert-base)	한국어 표준 벤치마크 기반 모델	KLUE 벤치마크 기반 학습, 한국어 범용 문서 분류에 안정적
KR-BERT (snunlp/KR-BERT-char16424)	Char-level 한국어 BERT	자소 기반 단어 표현 가능, 희귀어/오타에 상대적 강점, 일반 문서에서는 성능 평이

→ BERT 계열 모델들 중에서는 일반화 성능과 생태계 호환성 측면에서 bert-base-multilingual-cased가 가장 적합하였으며, 특히 법률 문서처럼 긴 문장과 복잡한 문맥을 다루는 작업에 강점을 보였다.

● 실험 모델 수: 총 5종

모델	**Accuracy**	**F1 Score**	**특징 요약**
beomi/KcBERT-base	0.9821	0.9751	SNS 표현력, 한국어 강점
bert-base-multilingual-cased	0.9821	0.9750	다국어 대응력, 긴 문장 적합
klue/bert-base	0.9821	0.9725	한국어 범용 안정성
snunlp/KR-BERT-char16424	0.9821	0.9725	자소 기반 특화

● 최종 선정 모델: bert-base-multilingual-cased

BERT 계열 모델 중에서는 **bert-base-multilingual-cased**가 **다국어 문서 처리 및 긴 문장 이해에 강점을 보였으며**, 모델 안정성과 생태계 호환성도 뛰어나 **법률 문서 분류와 같은 복잡한 작업에 적합**한 것으로 판단됨

2. 모델 구조 및 아키텍처

2.1 모델 아키텍처 도식

[입력층: 판례 본문 텍스트]

↓

[Tokenizer: WordPiece 방식 토큰화]

↓

[임베딩층]

└── Token Embedding

└── Positional Embedding

└── Segment Embedding

↓

[인코더 블록 × 12]

└── Multi-head Self-Attention

└── Feed Forward Network

↓

[CLS 토큰 벡터 추출]

↓

[분류기 출력층: Linear → Softmax]

↓

[출력: 클래스 확률 분포 (총 6개 클래스)]

2.2 구성 요소 설명

계층명	역할	구성 요소
Embedding	입력 판례 문장을 벡터화	WordPiece Tokenizer + Token/Position/Segment Embedding
Encoder	문맥 기반 의미 표현 학습	Multi-Head Self-Attention + Feed Forward Network (×12)
CLS 추출	문장 전체의 의미 요약	인코더 마지막 층의 [CLS] 토큰 벡터 사용
Classification Head	판례 결과 클래스 예측	Dense Linear Layer + Softmax (출력 노드 수: 6개)

3. 학습 설정 및 하이퍼파라미터

항목	값
학습 데이터 수	2,126 건
검증 데이터 수	112건
에폭(Epoch) 수	3
배치 크기 (Batch Size)	8
학습률 (Learning Rate)	5e-5
옵티마이저	AdamW
손실 함수	CrossEntropyLoss
조기 종료 기준	없음

4. 학습 결과 및 성능 평가

4.1. 학습 결과 요약

결과명	방식	스케줄러	검증 방식	특징
A. 기본 학습	단순 Trainer.train() 사용	X	단일 validation	가장 단순한 베이스라인 학습
B. 과적합 방지 적용	Scheduler + Warmup 적용	O	단일 validation	성능 정체 구간에서 학습률 조정, Dropout 기본 적용
C. 교차 검증 적용	K-Fold Cross Validation (5-fold)	O	K개의 validation	데이터 분산 고려, 일반화 성능 평가에 적합

결과명	Accuracy	F1 Score	Loss	특이사항
A. 기본 학습	0.9821	0.9638	0.0867	빠른 학습 속도, 일부 과적합 가능성 있음
B. 과적합 방지 적용	0.9911	0.9824	0.0574	가장 높은 성능 기록, 안정적인 학습 성과
C. 교차 검증 적용	0.9673	0.9602	N/A	일반화에 유리, 단일 평가 손실(loss)은 없음 (fold 평균)

- Regularized 방식이 Accuracy와 F1 모두에서 가장 우수한 성능을 보였으며, eval_loss도 가장 낮아 일반화 성능이 뛰어난 것으로 평가됨.

클래스	Precision	Recall	F1 Score
0	1.00	0.85	0.92
1	0.89	0.94	0.91
2	0.93	0.93	0.93
4	1.00	1.00	1.00
5	0.86	1.00	0.92
7	1.00	1.00	1.00

4.2 해석 및 분석

클래스별 분류 성능 해석

- ◇ **클래스별 강점**
  - 클래스 4, 7 (*파기환송, 파기환송+원심유지*)에서 **Precision, Recall, F1 = 1.00** → 완벽하게 분류
  - 클래스 2는 모든 지표에서 0.93 수준 → **안정적인 예측 성능**
- ◇ **오분류 경향**
  - 클래스 0 (Recall 0.85) → 일부 누락
  - 클래스 1은 Precision 0.89로 비교적 낮았고, 0 및 2와 **의미상 유사성**으로 인한 혼동 가능성 있음
- ◇ **클래스 불균형 영향 미미**
  - macro avg와 weighted avg가 각각 0.95, 0.96으로 큰 차이 없음
  - **소수 클래스도 높은 예측 성능** 확보

5. 과적합/과소적합 대응

● 적용 기법

기법	설명	적용 여부
Dropout	과적합 방지를 위해 일부 뉴런 무작위 비활성화	O 기본 적용 (BERT 기본값 0.1 사용)
조기 종료 (Early Stopping)	일정 에폭 이상 성능 개선 없을 시 학습 중단	X 미적용 (Trainer 설정에 없음)
학습률 감소 (LR Scheduler)	성능 정체 시 학습률을 줄여 미세한 튜닝 가능	O Regularized 실험에서 적용
교차 검증 (K-Fold CV)	데이터 분산을 고려한 일반화 성능 평가 기법	O KFold 실험에서 적용

● **결과**

- BERT의 사전학습 구조 내 Dropout 적용으로 인해 과적합은 나타나지 않음
- 에폭 수가 적고 validation loss와 train loss 간 차이가 작아, 성능은 안정적으로 수렴
- 다만, 조기 종료 기법은 적용되지 않아 추후 모델 튜닝 시 도입 가능

6. 결론 및 향후 계획

● **최종 선정 모델**

- bert-base-multilingual-cased (다국어 지원 사전학습 모델 기반)

● **활용 방안**

- **판례 분류기**로 활용하여, 사용자 질의에 대한 적절한 판례 응답을 자동 선별
- **사례 유사도 기반 추천** 시스템의 사전 분류 필터로 연동 가능

● **향후 계획**

- 테스트 데이터셋을 기반으로 실환경 유사 조건에서 모델 성능 추가 평가 예정
- 모델 추론 속도 개선을 위해 TinyBERT, Knowledge Distillation 기반 경량화 고려

7. 부록

관련 상세 정보 : https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN10-FINAL-3Team.git