SK네트웍스 **Family AI** 과정 **10**기

모델링 및 평가 수집된 데이터 및 전처리 문서

□ 개요

- 산출물 단계 : 모델링 및 평가
- 평가 산출물 : 수집된 데이터 및 전처리 문서
- 제출 일자 : 2025.06.20
- 깃허브 경로 : https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN10-final-3Team
- 작성 팀원 : 김현수

1. 데이터 수집 개요

데이터 수집 기간: 2025.05.12 ~ 2025.05.25

수집 방식:

- API
  - 국가법령정보 공동활용
  - 활용 라이브러리
    - requests
    - beautifulsoup
- 크롤링
  - 대한민국 법원 사법정보공개포털
  - 활용 라이브러리
    - selenium
    - beautifulsoup

1.1 수집 목적

수집 목적:

- 사건 내용을 기반으로 변호 전략을 수립에 도움을 주는 모델을 개발하기 위함.

1.2 데이터 출처

데이터명	출처	수집 방식	형식
판례 데이터	국가법령정보 공동활용	API 수집 (JSON)	JSON
	대한민국 법원 사법정보 공개 포털	웹 크롤링	JSON

1.3 수집 대상 및 범위

- 대상: 판례 데이터 **(1986.12.09 ~ 2025.03.27)**
- 총 수집 건수: **3482** 건 **(API 2432** 건 **+** 크롤링 **1050** 건**)**
- 개인정보 포함 여부:
  - 확인 된 개인정보: 변호사 이름, 법관 이름, 법무법인명

1.4 법적·윤리적 고려 사항

- 상업적 이용 가능
  - 국가법령정보 공동활용의 저작권 정책
- 보호받지 못하는 저작물로 분류
  - 법제처 저작권법 제7조
- 데이터 사용 승인

2. 저장 방식

OPEN API 데이터

- 저장 경로: data/api_data/
- 저장 형식: JSON

크롤링 데이터

- 저장 경로 : data/crawling_data/
- 저장 형식: JSON

2.1 중복 및 정합성 검증

- 중복 제거 기준**:** 사건번호 기준 중복 제거
- 정합성 확보 방법**:**
    - 빈 질문 / 답변 제거

3. 데이터 전처리 절차

3.1 수집 데이터 전처리

3.1.1 데이터 정제

- **API** 데이터
  - 필요 columns 추출
- 크롤링 데이터
  - 불필요한 공백 제거 및 특수 문자의 반복 제거 (‘\n\n…’, ‘\t\t…’) 제거
  - 중복된 판례 제거
  - API 데이터에서 필요
    columns 추출한 것과 동일하게 추출하기 위해 본문 에서 데이터 추출
- **이후 하나의 csv로 통합**

	사건번호	법원명	사건명	선고일자	참조판례	참조조문	판결요지	판례내용	판시사항
0	96다24668	대법원	손해배상(자)	19980515	[1] 대법원 1980. 3. 25. 선고 80다68 판결(공1980, 12742)...	[1] 민사소송법 제261조 / [2] 민법 제393조, 제763조 / [3] 민법...	[1] 타인의 불법행위로 인하여 피해자가 상해를 입게 되거나 사망하게 된 경우,...	【원고, 피상고인】 원고 (소송대리인 변호사 정장훈)\n 【피고, 상고인】 동부화...	[1] 불법행위로 인한 손해배상 청구소송에서 피해자의 사고 당시 수입이 자백의 대상...
1	97다58538	대법원	손해배상(기)	19980515	[1] 대법원 1969. 1. 28. 선고 67다2522 판결(집17-1, 민80)...	[1] 민법 제756조, 상법 제24조 / [2] 민법 제756조 / [3] 민법 ...	[1] 타인에게 어떤 사업에 관하여 자기의 명의를 사용할 것을 허용한 경우에 그...	【원고, 피상고인】 한라해운 주식회사 (소송대리인 변호사 김현 외 2인)\n 【피...	[1] 명의사용자의 업무수행상 불법행위에 대한 명의대여자의 사용자책임 유무(적극)\...
2	97다57689	대법원	손해배상(기)	19980522	[1][2] 대법원 1993. 11. 26. 선고 93다18389 판결(공1994상...	[1] 민법 제751조, 형법 제307조, 제310조 / [2] 민법 제751조, ...	[1] 일정한 행정목적 달성을 위하여 언론에 보도자료를 제공하는 등 이른바 행정...	【원고, 상고인】 원고 주식회사 (소송대리인 법무법인 두레 담당변호사 노승행)\n 【...	[1] 행정상 공표의 방법으로 실명을 공개함으로써 타인의 명예를 훼손한 경우, 그 ...
3	98다11635	대법원	손해배상(기)	19980526		[1] 국가배상법 제2조 / [2] 민법 제103조\n	[1] 가해자가 피해자를 살해하기 직전까지 오랜 기간에 걸쳐 원한을 품고 집요하...	【원고, 피상고인】 원고 1 외 3인 (원고들 소송대리인 변호사 홍기배)\n 【피고,...	[1] 피해자로부터 범죄신고와 함께 신변보호요청을 받은 경찰관의 보호의무 위반을 인...
4	96다11648	대법원	손해배상(기)	19980529	[1][2] 대법원 1992. 11. 10. 선고 92다4680 전원합의체 판결(공...	[1] 민사소송법 제557조, 제696조 / [2] 민법 제750조, 민사소송법 제...	[1] 부동산소유권이전등기청구권을 가압류하였다 해다라도, 어떠한 경로로 제3채무...	【원고, 피상고인】 신용보증기금 (소송대리인 법무법인 부산 담당변호사 허진호)\...	[1] 소유권이전등기청구권의 가압류 후 어떤 경로로 제3채무자로부터 채무자 명의로 ...
5	97다49404	대법원	손해배상(기)	19980609	[1][2] 대법원 1993. 8. 27. 선고 93다22357 판결(공1993하,...	[1] 민법 제750조, 제755조 / [2] 민법 제750조, 제755조\n	[1] 책임능력 있는 미성년자의 불법행위로 인하여 손해가 발생한 경우 그 손해와...	【원고, 피상고인】 원고 1 외 2인 (원고들 소송대리인 변호사 이용우)\n 【피고,...	[1] 책임능력 있는 미성년자의 불법행위에 대한 감독의무자의 손해배상책임\n[2] ...
6	96다55631	대법원	손해배상(자)	19980612	[1] 대법원 1982. 6. 8. 선고 81다카1130 판결(공1982, 638)...	[1] 민법 제750조, 제760조 / [2] 민법 제396조, 제760조, 제76...	[1] 공동불법행위의 성립에는 공동불법행위자 상호간에 의사의 공통이나 공동의 인...	【원고, 상고인】 원고 1 외 7인 (원고들 소송대리인 변호사 최윤학)\n 【피고, ...	[1] 공동불법행위의 성립 요건\n[2] 공동불법행위책임에 대한 과실상계에 있어서 ...
7	97다29424	대법원	손해배상(기)	19980612	[1] 대법원 1967. 9. 5. 선고 67다1014 판결(집15-3, 민6) ...	[1] 민법 제393조, 제763조 / [2] 민법 제393조, 제763조\n	[1] 타인의 불법행위로 인하여 취득할 수 있었던 목적물을 취득하지 못한 경우에...	【원고, 피상고인】 원고 (소송대리인 변호사 허정훈)\n 【피고, 상고인】 피고 (소...	[1] 타인의 불법행위로 인하여 취득할 수 있었던 목적물을 취득하지 못한 경우 손...
8	98다14252, 14269	대법원	채무부존재확인, 손해배상(자)	19980612	대법원 1985. 1. 22. 선고 84도1493 판결(공1985, 386), 대법...	민법 제750조, 도로교통법 제22조\n	신호등에 의하여 교통정리가 행하여지고 있는 교차로를 녹색등화에 따라 진행하는 차...	【원고(반소피고), 상고인】 현대해상화재보험 주식회사 (소송대리인 변호사 김병찬...	신호등에 따라 교차로를 통과하는 차량 운전자에게 신호가 바뀐 후 다른 자량이 신호를...

3.2 요약 및 키워드 데이터 생성

- 개요:
  - 로컬 모델(Gemma3-4b-it) 모델을 이용하여 판례 내용을 기반으로 사실관계 요약, 사실관계 키워드, 쟁점 요약, 쟁점 키워드를 추출 및 생성
- 생성 과정:
  - google/gemma3-4b-it 모델 호출

```python
llm = LLM(
    model="google/gemma-3-4b-it",
    tokenizer="google/gemma-3-4b-it",
    dtype="bfloat16",
    trust_remote_code=True,
    gpu_memory_utilization=0.9
)
```

○ 판례내용을 input으로 요약 및 키워드 생성

사건번호	사실관계 요약	사실관계 키워드	쟁점 요약	쟁점 키워드
96다24668	원고는 농업 및 양어업을 영위하던 중 교통사고를 당해 경추 및 흉요추부 척추강 협착...	['교통사고', '일실수입', '척추손상', '자영업', '수입산정']	주요 쟁점은 원고의 사고 당시 수입을 산정하는 데 사용된 임금구조기본통계조사보고서의...	['수입산정', '임금구조기본통계조사', '자영업', '법리오해', '증거의 가치']
97다58538	한라해운은 고철 수입 과정에서 아사르 인터내셔널의 허위 선적 준비 보고를 믿고 용선...	['고철 수입', '용선계약', '허위 보고', '기망', '감독']	재판의 핵심 쟁점은 피고 회사(피고 1)가 피고 3의 고철 수입 사업에 대한 감독 ...	['사용자 책임', '감독 의무', '허위 보고', '손해배상', '기망']
97다57689	주식회사(원고)가 'OOO막걸리'의 품질 문제(사카린나트륨 함유)를 언론에 공표하자...	['막걸리', '사카린', '검사', '유통', '가짜']	피고의 'OOO막걸리' 공표가 명예훼손에 해당하는지 여부가 쟁점입니다. 피고가 시료...	['진실성', '확증', '조사', '위법성', '입증']
98다11635	경찰관 소외 1이 이혼녀 소외 2를 지속적으로 괴롭히고 살해한 사건입니다. 소외 2...	['괴롭힘', '신변보호', '살해', '협박', '신고']	소외 1의 행위가 폭력행위등처벌에관한법률위반죄에 해당하고, 소외 2의 신변보호 의무...	['신변보호의무', '폭력행위', '연대책임', '의무위반', '범죄의증단']
96다11648	신용보증기금(원고)은 삼익목재(상고인)가 소유한 울산 공업기지 공장부지 조성사업 관련...	['토지 환지', '소유권이전등기청구권', '가압류', '계약 체결', '부동산']	가압류 목적물이 실제 환지된 토지와 동일한지 여부가 쟁점이다. 원심은 가압류 목적물...	['환지확정', '가압류효력', '불법행위', '손해배상책임', '등기청구권']

3.3 소송 전략 데이터 생성 (파인튜닝 데이터)

- 개요:
  - OpenAI API를 활용하여 판례 데이터를 기반으로 원고 혹은 피고의 입장에서 소송 전략 데이터 생성
- 생성 과정:
  - OpenAI의 모델 중 GPT 4o 모델 호출

```python
for context in tqdm(df['판례내용']):
    retry_count = 0
    while True:
        try:
            response = client.chat.completions.create(
                model="gpt-4.1",
                messages=[
                    {"role": "system", "content": prompt},
                    {"role": "user", "content": context}
                ],
                temperature=0,
                max_tokens=2048
```

  - 학습시킬 input 데이터와 output 데이터를 생성

```
{'input': {'사건내용': '1950년 6월 25일 한국전쟁 발발 직후, 내무부 치안국은 전국 경찰에 요시찰인 등 예비검속 및 형
  '청구내용': '원고 1(망인의 처), 원고 2, 3(망인의 자녀)은 피고 대한민국을 상대로, 1950년 6월 28일경 경찰 및 군에
  '증거자료': ['예비검속자 명부 및 총살자 명부 등 당시 경찰·군 내부 문서',
   '망인의 유족들이 제출한 각종 신고서(양민학살진상규명신고서, 희생자 신고서, 진실규명신청서 등)',
   '진실·화해를 위한 과거사정리위원회 진실규명결정서',
   '제주4·3사건 진상규명 및 희생자 명예회복 실무위원회 결정 통지',
   '제주특별자치도 4·3사업소장 발행 DNA 분석 결과 통지',
   '장례비 지출 관련 영수증 및 회계자료']},
 '원고_output': {'예상피고주장': ['손해 및 가해자를 안 날 또는 불법행위일로부터 소 제기까지 3년 또는 5년이 경과하이
  '당시 예비검속 및 총살이 국가 비상사태 하에서 이루어진 불가피한 조치였다고 주장할 가능성',
   '망인의 사망 경위 및 국가의 개입 여부에 대한 불확실성을 주장할 가능성',
   '장례비 등 재산적 손해의 범위 및 입증 부족을 지적할 가능성'],
  '전략방향성': ['소멸시효 주장에 대해, 망인의 사망 및 불법행위의 구체적 경위가 국가의 은폐 및 비밀리에 진행되어 유
   '진실·화해를 위한 과거사정리위원회 결정, 4·3사업소장 통지 등 공식적 확인 시점이 권리행사 가능 시점임을 부각',
   '예비검속 및 총살이 적법절차 없이 이루어진 불법행위임을 명확히 하고, 국가의 조직적 은폐 및 책임을 강조',
   '장례비 등 손해액 산정의 객관적 자료(영수증 등)와 정신적 손해에 대한 사회적·역사적 맥락을 부각'],
  '필요한증거': ['예비검속 및 총살 관련 경찰·군 내부 문서',
   '진실·화해를 위한 과거사정리위원회 진실규명결정서',
   '제주4·3사건 실무위원회 및 4·3사업소장 통지문',
   '망인의 유해 발견 및 DNA 분석 결과',
   '장례비 지출 관련 영수증 및 회계자료',
   '유족 진술 및 목격자 진술서'],
  '참고사항': '유사한 국가배상청구 사건에서 소멸시효 기산점, 국가의 은폐·비밀성, 진실규명 공식 결정 시점 등이 쟁점
 '피고_output': {'전략방향성': ['소멸시효 완성 주장에 초점을 맞추어 방어',
   '예비검속 및 총살의 경위와 국가의 직접적 개입 여부에 대한 불확실성 부각',
   '손해액 산정의 적정성 및 입증 부족 주장'],
  '방어논리': ['원고들이 망인의 사망 및 국가의 개입 사실을 1950년대에 이미 인지하였거나, 최소한 소문 등으로 알 수
   '예비검속 및 총살이 전시 비상사태 하에서 이루어진 조치로, 당시 상황의 특수성을 고려해야 한다고 주장',
```

- 파인튜닝 시 형식 변환

○ google/gemma-3–4b-it 모델의 사전학습 형태에 맞추어 아래와 같이 데이터 형식 변환

<eos><start_of_turn>user

{input}

<end_of_turn><start_of_turn>model

{output}

<end_of_turn>

```python
def format_prompt(example):
  formatted = f"<bos><start_of_turn>user\n{example['input']}<end_of_turn>\n"
  formatted += f"<start_of_turn>model\n{example['output']}<end_of_turn>\n"
  return {"text": formatted}

dataset = dataset.map(format_prompt)
dataset = dataset.map(lambda x: tokenizer(x["text"], truncation=True, padding="max_length", max_length=2048), batched=True)

dataset
```

```
'<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 망아(망인)는 피고 학교법인이 운영하는 병원에서
'<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 원고는 오랜 기간 동안 상당한 규모로 주식투자를
'<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 원고는 오랜 기간 동안 상당한 규모로 주식투자를
"<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 피고2는 대학에서 무역학을, 피고1은 경영학을 전
"<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 피고2는 대학에서 무역학을, 피고1은 경영학을 전
"<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 원고 주식회사 우리은행은 1997년경 대우전자 주
"<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 원고 주식회사 우리은행은 1997년경 대우전자 주
"<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 원고는 1999년 2월 24일 부여군 보건소에서 폐결
"<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 원고는 1999년 2월 24일 부여군 보건소에서 폐결
'<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 원고 1은 1983년경 고혈압이 발병하여 1997년경부
'<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 원고 1은 1983년경 고혈압이 발병하여 1997년경부
'<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 원고는 소외인(원고의 남편)과 혼인관계에 있었으
'<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 원고는 소외인(원고의 남편)과 혼인관계에 있었으
'<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 해태제과 주식회사는 에이스제과 주식회사의 대표
'<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 해태제과 주식회사는 에이스제과 주식회사의 대표
'<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 1999년 10월 21일, 원고는 사고로 인해 심각한 노
'<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 1999년 10월 21일, 원고는 사고로 인해 심각한 노
"<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 1999년 3월 31일, 원고(선정당사자) 및 선정자 등
"<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 1999년 3월 31일, 원고(선정당사자) 및 선정자 등
'<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 원고는 1950년 11월 학도의용군으로 입대하여 육
'<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 원고는 1950년 11월 학도의용군으로 입대하여 육
'<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 원고 손주원 외 2인은 피고 변호사에게 유한회사
'<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 원고 손주원 외 2인은 피고 변호사에게 유한회사
'<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 고려생명보험 주식회사는 1996년 4월 1일 계열사
'<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 고려생명보험 주식회사는 1996년 4월 1일 계열사
'<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 원고 성림산업진흥 주식회사는 피고(파산자 주식
'<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 원고 성림산업진흥 주식회사는 피고(파산자 주식
"<bos><start_of_turn>user\n\n해당 사건에서 원고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 원고\n사건 내용: 2003년 3월 24일 23:48경, 소외 1은 혈중알코올농
"<bos><start_of_turn>user\n\n해당 사건에서 피고를 변호하기 위한 전략을 작성해주세요.\n변호 대상: 피고\n사건 내용: 2003년 3월 24일 23:48경, 소외 1은 혈중알코올농
```

4. 사용 계획

- 수집 데이터
  - 판례DB에 저장하여 판례 메타 정보기반 조회 시 사용
  - 판례내용의 경우 VectorDB에 저장하여 유사도 검색 시 사용
- 요약 및 키워드 데이터
  - 판례DB에 사건번호와 매칭하여 저장
  - VectorDB에 저장하여 유사도 검색 시 사용
- 소송 전략 데이터
  - 파인튜닝 데이터 활용
    - input(Instruction, 사건내용, 청구내용, 증거자료)
    - 원고_output(예상 피고 주장, 전략 방향성, 필요한 증거, 참고사항)
    - 피고_output(전략 방향성, 방어논리, 참고사항)
  - 가상의 사건접수 데이터 활용
    - 판례 데이터와 Input(사건내용, 청구내용, 증거자료)를 통하여 서비스를 이용하는 가상의 법무법인의 사건 등록